


# TP558 - Tópicos avançados em Machine Learning:

A Novel PAPR Reduction Scheme for OFDM System  
based on Deep Learning




# Introdução

- A evolução dos sistemas de comunicações moveis tem proporcionado um aumento expressivo na taxa de transmissão e na quantidade de novos usuários na rede.
- Este crescimento se deu principalmente apos a popularização de serviços de streaming e comunicação em tempo real por voz e vídeo.
- Desta forma, os dispositivos moveis estão sujeitos a dividir um recurso que, com a inclusão de novos usuários, torna-se cada vez mais escasso.
- Para contornar a escassez espectral, as agencias reguladoras internacionais sugeriram utilizar o espectro ocioso de canais de TV — também conhecido por Television White Spaces (TVWS) — mediante uma serie de restrições

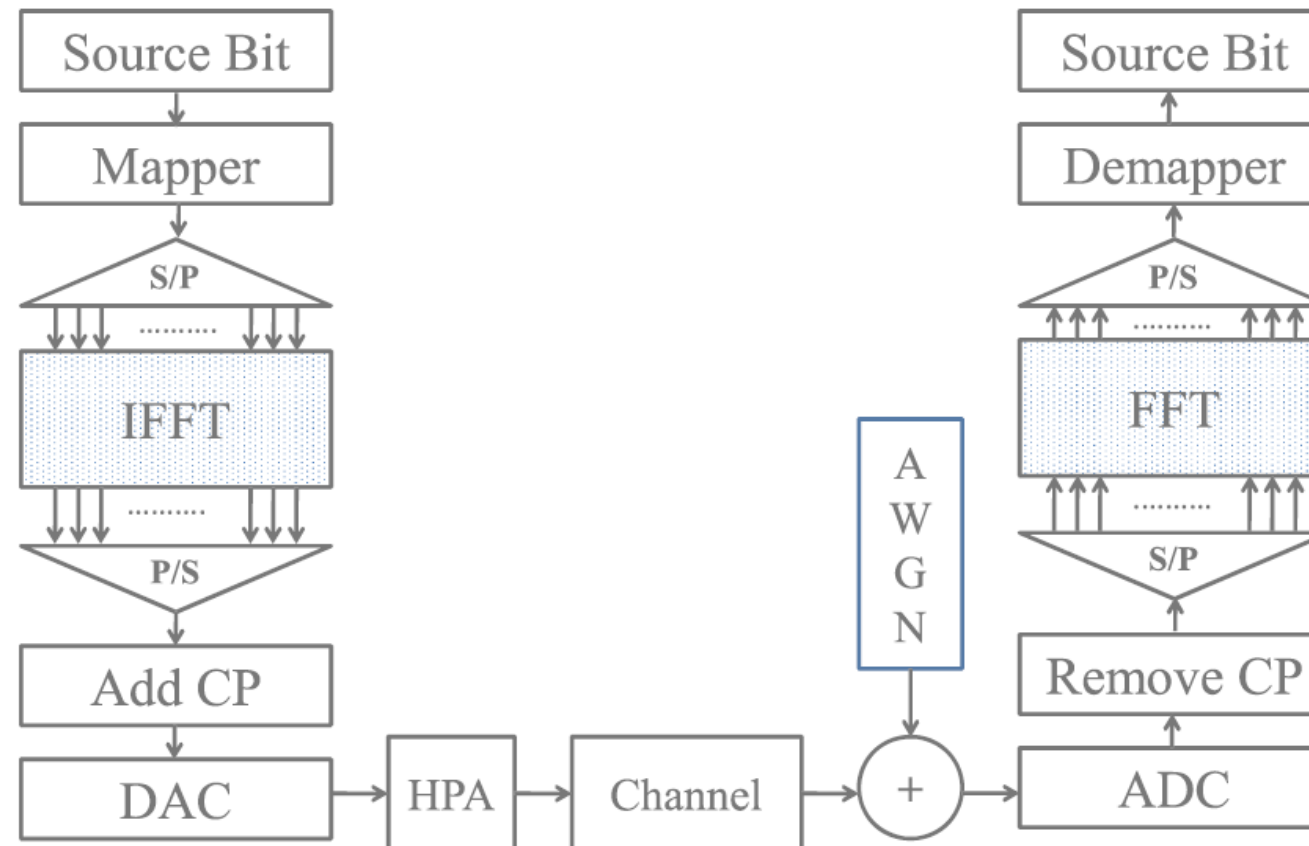
# Fundamentação teórica

- OFDM
- Forma de onda multiportadora



# Fundamentação teórica


- OFDM



# Fundamentação teórica

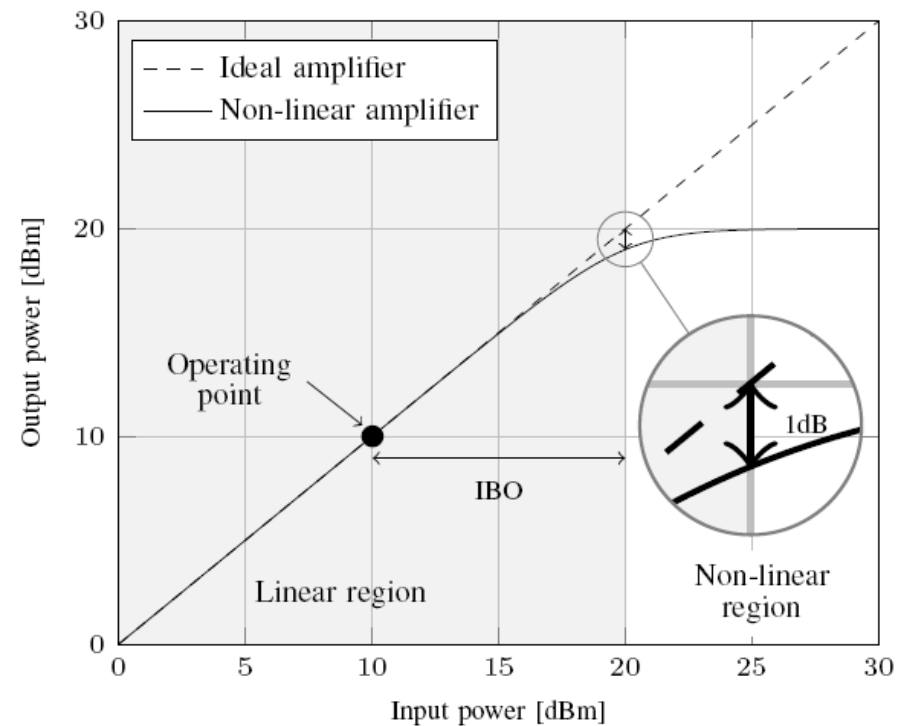
- OFDM
- Alta PAPR(peak-to-average power ratio)

$$\text{PAPR}_{x(n)} = \frac{\text{Max}_n [|x(n)|^2]}{E[|x(n)|^2]},$$



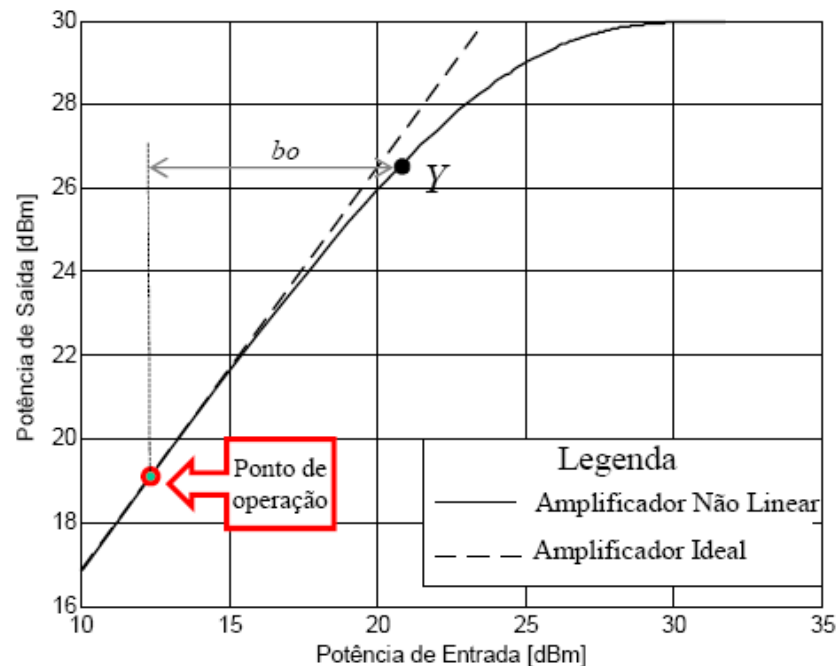
# Fundamentação teórica

- OFDM
- Amplificador de potência não linear



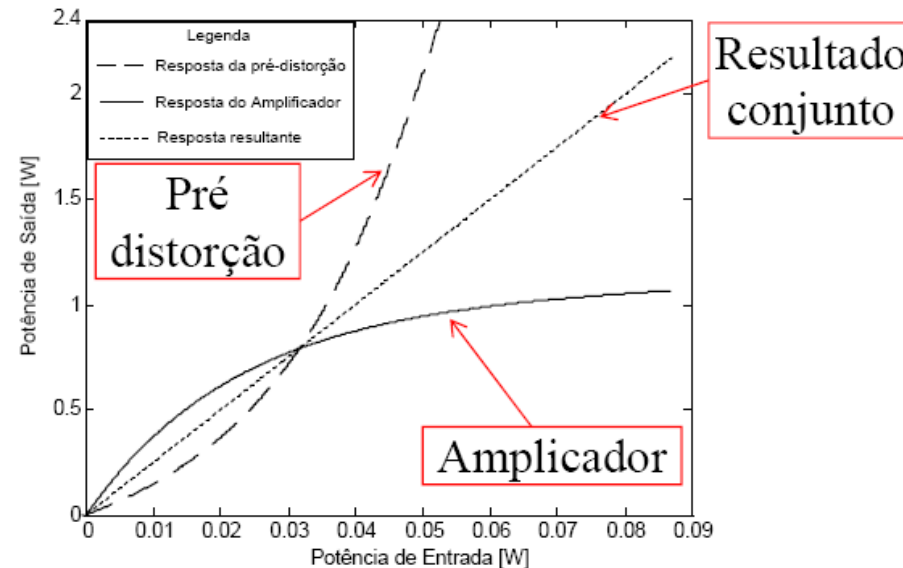
# Fundamentação teórica

- OFDM
- Back-off
  - Esta técnica consiste em um projeto de amplificador ao qual desloca o valor do ponto de potência média do sinal de entrada alguns dBs abaixo do ponto de compressão de 1dB.
  - Não é uma técnica muito utilizada pois apresenta uma baixa eficiência energética.



# Fundamentação teórica

- OFDM
- Pré-distorção
  - Técnica que consiste em distorcer o sinal de entrada antes de passar pela parte de amplificação
  - O sinal distorcido quando passa pelo amplificador recupera sua forma original.
  - O sinal distorcido pode ser estático ou dinâmico.



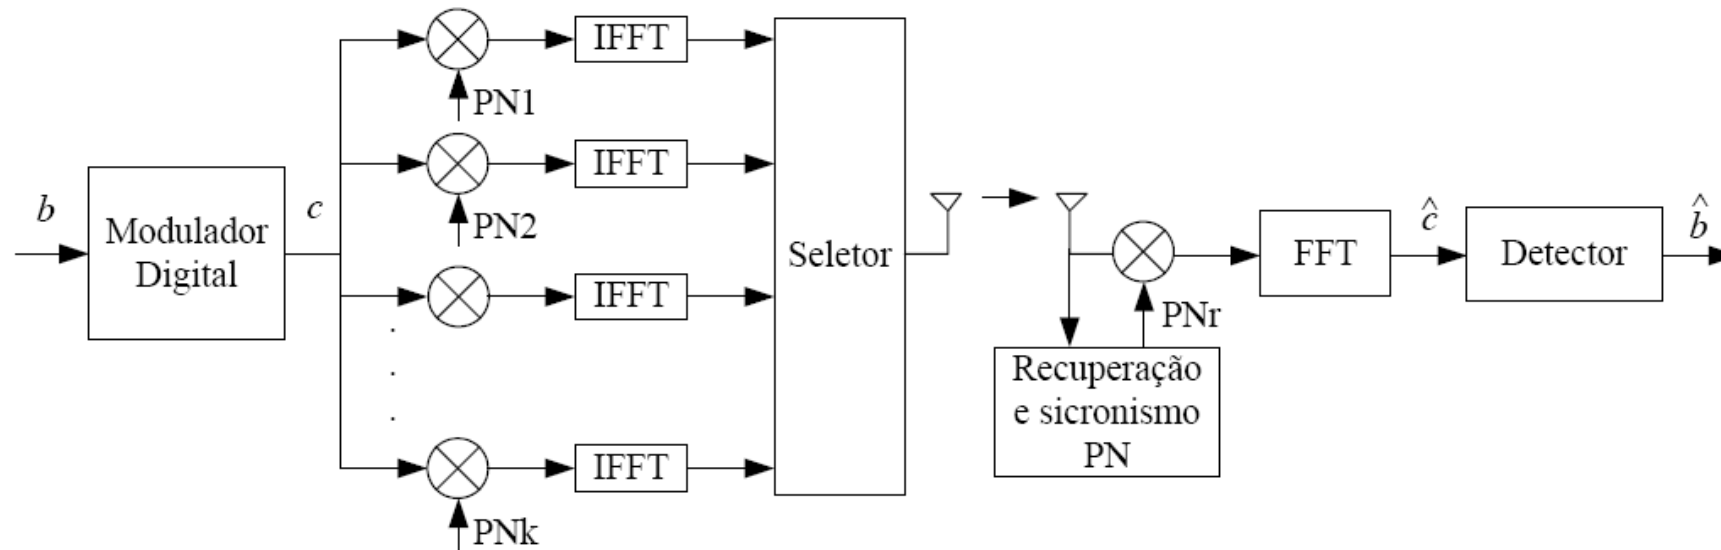


# Fundamentação teórica

- OFDM
- SLM-OFDM (Selective Mapping)
- Técnica que consiste em multiplicar a sequência de dados a ser transmitidos por  $k$  sequencias PN diferentes.
- Estas sequencias geradas serão enviadas a um seletor que determina a que tem a menor PAPR para ser transmitida.
- O transmissor deve informar ao receptor qual foi a PN selecionada para que ele possa recuperar os dados.
- Com isso, o receptor deve conhecer todas as sequencia PN do transmissor.
- Podem ser aplicadas diferentes sequencias para realizar a redução da PAPR.

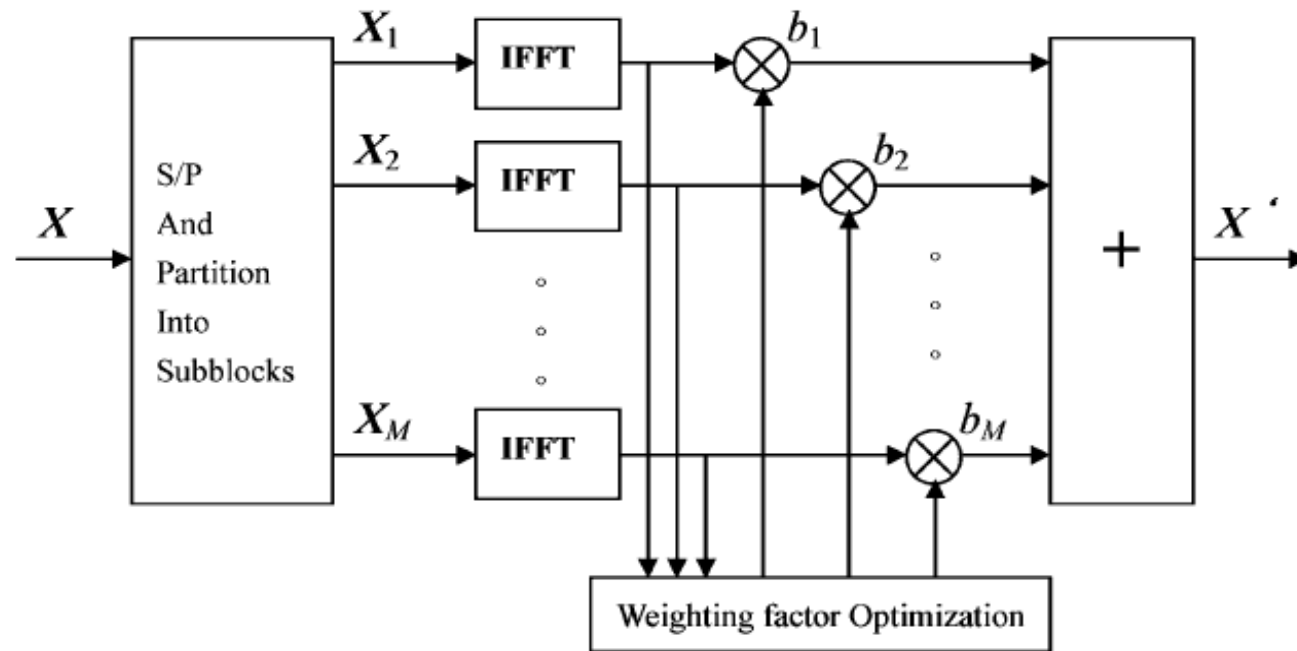
# Fundamentação teórica

- OFDM



# Fundamentação teórica

- OFDM
- PTS-OFDM (Partial Transmit sequence)
  - Essa técnica baseia-se em subdividir os dados de entrada em sub-blocos disjuntos. Cada sub-bloco é multiplicado por um fator de ponderação, que é obtido por um algoritmo de otimização para reduzir o valor da PAPR



# Fundamentação teórica

- OFDM

- Esquema para redução de PAPR baseado em PRNet Deep Learning
  - O artigo – A Novel PAPR Reduction Scheme for OFDM System Based on Deep Learning - utiliza o esquema de redução conhecido como Rede de redução (PRNet) da PAPR, em que baseia-se em uma arquitetura de auto encoder de aprendizado profundo.
  - Neste sistema, a constelação de mapeamento e demapeamento do símbolo de cada subportadora do OFDM são fundidos na técnica DL.


# Arquitetura e funcionamento

- **Deep Learning** é uma subárea do **Machine Learning (Aprendizado de Máquina)**, que por sua vez é uma subárea da **Inteligência Artificial (IA)**.
- A ideia central é permitir que um computador **aprenda padrões complexos a partir de grandes quantidades de dados, sem precisar ser explicitamente programado** para isso.

# Arquitetura e funcionamento

- A diferença principal entre *Machine Learning tradicional* e *Deep Learning* está na **estrutura dos modelos**:
  - **Machine Learning tradicional** usa algoritmos mais simples (como regressão linear, árvores de decisão, SVMs etc.) e exige **engenharia manual de features** — ou seja, o humano precisa decidir quais características dos dados são relevantes.
  - **Deep Learning**, por outro lado, usa **redes neurais artificiais profundas** que **aprendem automaticamente** quais características são mais importantes, a partir dos próprios dados.

# Arquitetura e funcionamento

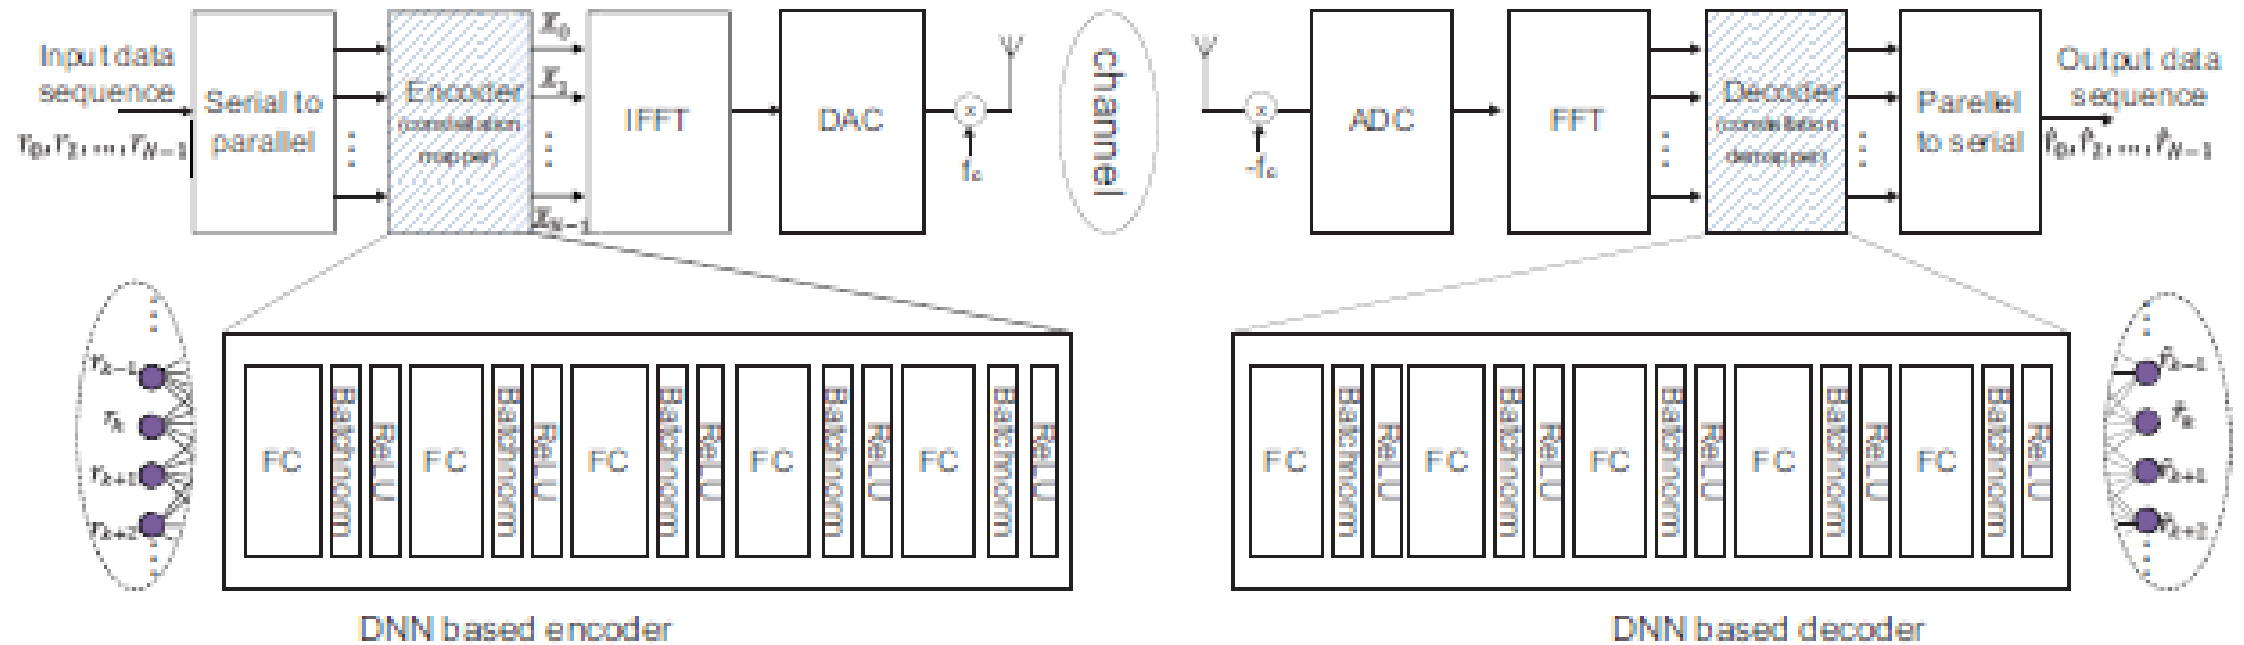
-  **Como o Deep Learning “aprende”?**
- O aprendizado acontece em três etapas principais:
- **Propagação direta (forward pass)**
  - Os dados entram na rede e passam camada por camada.
  - Cada neurônio faz uma combinação linear das entradas (soma ponderada) e aplica uma **função de ativação** (como ReLU, sigmoid, tanh) para introduzir *não linearidade*.
  - O resultado final é comparado com a resposta correta (rótulo verdadeiro).

# Arquitetura e funcionamento

- **Cálculo do erro (função de perda / loss function)**
  - Mede o quanto a previsão está distante do valor real.
  - Exemplos: *Mean Squared Error* (para regressão), *Cross-Entropy Loss* (para classificação).
- **Retropropagação (backpropagation)**
  - O erro é propagado para trás, ajustando os pesos usando o **gradiente descendente (gradient descent)** — um método de otimização que tenta reduzir o erro a cada iteração.
- Esse processo é repetido muitas vezes (**épocas**), até que a rede aprenda os padrões do conjunto de dados.



# Arquitetura e funcionamento



- FC = fully connected layer
- batch normalization (Batchnorm),
- rectifier linear unit (ReLU)

# Arquitetura e funcionamento

- $y_{FC} = \mathcal{W}_m x_{FC} + b_m$
- Onde  $\mathcal{W}_m$  e  $b_m$  são os pesos e o bias para a  $m$ -th FC.
- $|y_{FC}| = \gamma \frac{y_{FC} - E[y_{FC}]}{\sqrt{Var[y_{FC}] + v}} + \beta$
- Onde  $\gamma$  e  $\beta$  são os fatores de escala e deslocamento e  $v = 0,001$  é a constante para evitar divisão por zero.

$$\bar{\tilde{f}}(\tilde{\mathbf{r}}) = \phi_{L_f}(\|\mathbf{W}_{L_f}^f \phi_{L_f-1}(\cdots \phi_1(\|\mathbf{W}_1^f \mathbf{r} + b_1^f|_{norm}) \cdots) + b_{L_f}^f|_{norm}),$$

# Arquitetura e funcionamento

- Onde  $\mathbf{W}_{L_f}^f$  e  $\mathbf{b}_{L_f}^f$  são os pesos e os bias da  $l$ -th FC do encoder.
- E

$$g(\mathbf{y}) = \phi_{L_g}(\mathbf{W}_{L_g}^g \phi_{L_g-1}(\cdots \phi_1(\mathbf{W}_1^g \mathbf{y} + \mathbf{b}_1^g|_{norm}) \cdots) + \mathbf{b}_{L_g}^g|_{norm})$$

- é a saída do decoder.

# Arquitetura e funcionamento

$$\mathcal{L}_1(\mathbf{r}, \hat{\mathbf{r}}) = \|\mathbf{r} - g(FFT(\mathbb{H} \circ IFFT(f(\mathbf{r}; \theta_f)) + \epsilon); \theta_g)\|_2,$$

$$\mathcal{L}_2(\mathbf{r}) = PAPR\{x[n]\} = PAPR\{IFFT(f(\mathbf{r}; \theta_f))\}.$$


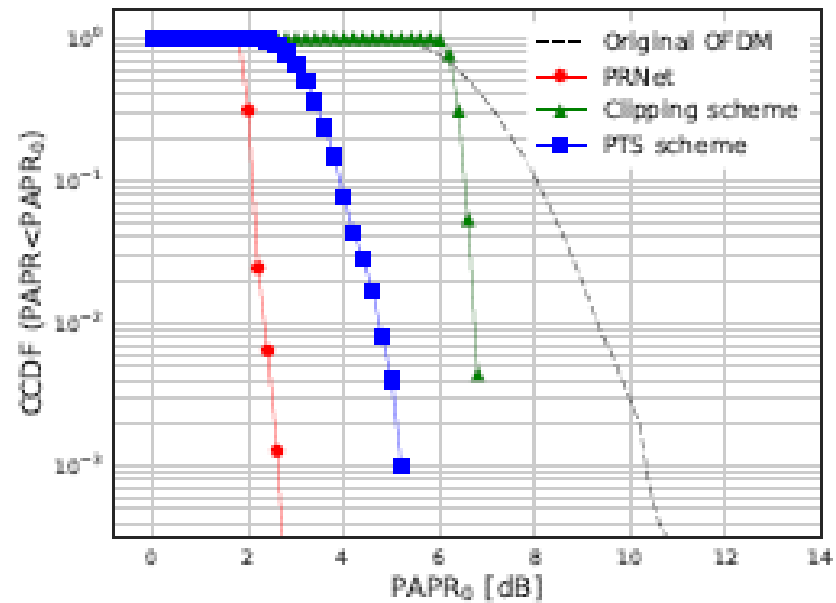
$$\mathcal{L}(\mathbf{r}, \hat{\mathbf{r}}) = \mathcal{L}_1(\mathbf{r}, \hat{\mathbf{r}}) + \lambda \mathcal{L}_2(\mathbf{r}).$$

- Onde  $\lambda$  é o parâmetro que determina qual função de perda tem mais peso.


# Treinamento e otimização

- Dataset: tensorflow.examples.tutorials.mnist
- Treinamento
  - 500000 épocas
  - Batch size de 400
  - Otimizador é o Adam
  - E utiliza o SGD para atualização dos pesos
  - Inicialmente  $\lambda$  é definido como 0,01
- Teste
  - Batch size de 50000

# Treinamento e otimização



# Treinamento e otimização



# Vantagens e desvantagens

- Vantagens
  - Melhora da eficiência energética;
  - Gera menor interferência fora de faixa;
  - Aumento da área de cobertura;
  - Redução do custo de transmissão;
- Desvantagens
  - Aumento da complexidade computacional;
  - Aumento da latência do sistema;



# Exemplo(s) de aplicação

- Telefonia Móvel
- Rádio 5G RANGE
- Sistemas de comunicação via Satélite
- Sistemas de comunicação ópticos

# Comparação com outros algoritmos

- Complexidade do PRNet

$$O(L \cdot K \cdot M)$$

- Tempo de execução de 480μs em execução em paralelo e 2304μs no modo de execução normal;
- Tempo de execução de 2890μs para o PTS;
- Tempo de execução de 1415μs para o Cutting.

Perguntas?

# Referências

- [1] M. Kim, W. Lee and D. -H. Cho, "A Novel PAPR Reduction Scheme for OFDM System Based on Deep Learning," in *IEEE Communications Letters*, vol. 22, no. 3, pp. 510-513, March 2018, doi: 10.1109/LCOMM.2017.2787646.

# Quiz

- [https://docs.google.com/forms/d/e/1FAIpQLSe7jDBaE0\\_KSbCizrEnZR0yZjJHEqMalEzc2kh3psYYviJDSA/viewform?usp=sharing&ouid=106515288605627870283](https://docs.google.com/forms/d/e/1FAIpQLSe7jDBaE0_KSbCizrEnZR0yZjJHEqMalEzc2kh3psYYviJDSA/viewform?usp=sharing&ouid=106515288605627870283)

Obrigado!